


A decorative grid pattern of squares is visible in the top-left and top-right corners of the slide.

Optimizing Food Delivery Time Prediction

A Machine Learning Approach

A decorative graphic in the bottom-right corner consisting of a blue-to-green gradient circle with two white concentric arcs.

Introduction



Mochamad Fiqi Sabila

Motion Graphics Designer combining creativity and analytical thinking, currently transitioning into data science and analytics through hands-on experience and bootcamp learning.

A Machine Learning Approach

Education

dibimbing.id

Data Analyst & Data Science - Bootcamp
(Informal Education)



www.linkedin.com/in/mochamadfiqi



github.com/mfigii

Previous Project

FINAL PROJECT DATA ANALYST

Peran Public Awareness terhadap Kapasitas Energi Terbarukan: Analisis Data 2023



Slides



Github



Previous Project

FINAL PROJECT DATA SCIENCE

Estimasi Harga *Resale* HDB Singapore 2017–2023



[Slides](#)



[Github](#)



Streamlit

[Streamlit App](#)



Project Background

Layanan food delivery makin kompetitif. **Ketepatan estimasi waktu antar** sangat krusial untuk kepuasan & retensi pelanggan.

Waktu kirim dipengaruhi banyak faktor: **jarak, waktu persiapan, lalu lintas, cuaca, pengalaman kurir**, dll.

Estimasi yang kurang akurat menjadikan ekspektasi pelanggan turun, komplain meningkat, potensi churn.

Problem Statement

1. **Bagaimana memprediksi Delivery Time secara akurat dari fitur operasional yang tersedia?**
 - Fitur seperti jarak, waktu persiapan makanan, kondisi cuaca, dan pengalaman kurir menjadi variabel utama yang dapat mempengaruhi lamanya waktu pengantaran.
2. **Algoritma mana (Linear Regression, Random Forest, XGBoost) yang paling optimal untuk kasus ini?**
3. **Faktor apa yang paling berpengaruh terhadap Delivery Time untuk dasar rekomendasi operasional?**
 - Hasil feature importance dapat memberikan insight untuk rekomendasi operasional dan strategi bisnis.

Success Metrics

- **MAE (menit)** – metrik utama (mudah diinterpretasi bisnis).
- **MAPE (%)** – error relatif.
- **RMSE (menit)** – sensitif pada error besar (late delivery).
- **R^2** – proporsi variasi Delivery Time yang dijelaskan model.


Target realistis (mengacu baseline saat ini): $MAE \leq \sim 6$ menit dan $MAPE \leq \sim 11\text{--}12\%$ (lebih baik = lebih kecil).

Data Understanding

Dataset ini diambil dari Kaggle, dengan total data sebanyak: **1000 baris, 9 fitur.**

Fitur utama: Distance, Preparation Time, Courier Experience, Weather, Traffic Level, Vehicle Type, Time of Day.

Target: **Delivery Time (minutes).**



Data Preprocessing

1

Handling Missing Values



Ditemukan adanya **missing value** pada kolom 'postal_code'.
Di-handle dengan cara menghapus kolom. Karena kolom 'postal_code' dianggap tidak relevan dalam analisis dan modeling

2

Removing Duplicates



Tidak ditemukan adanya duplicate pada dataset.

Data Preprocessing

4

Outlier Detection



Terdapat outlier, namun dengan nilai yang kecil dan tidak extreme. Serta berisikan data yang aktual.


5

Exploratory Data Analysis

Key Exploratory Findings

Distribusi target


- **Right-skewed**, banyak order selesai di sekitar 40–70 menit, tapi ada ekor panjang ke kanan (>100 menit).
- Ada beberapa outlier (**120–150 menit**)
- Distribusi ini masuk akal untuk problem delivery/logistics, karena mayoritas pengiriman on-time, tapi sebagian kecil bisa delay.



Key Exploratory Findings

Weather vs target


- **Clear**, median delivery time relatif paling rendah (~50 menit).
- **Rainy & Foggy**, median naik sedikit (~57–60 menit).
- **Snowy**, median tertinggi (~65 menit), dengan sebaran lebih lebar.
- **Windy**, median juga agak tinggi (~55 menit), tapi sebarannya tidak terlalu lebar.
- **Outlier** banyak muncul di semua kategori (hingga 150 menit), menunjukkan ada beberapa kasus ekstrem di tiap kondisi cuaca.



Key Exploratory Findings

Traffic Level vs target

- **Low traffic**, median sekitar **50 menit**, sebaran cukup rapat.
- **Medium traffic**, median naik sedikit (**~53–55 menit**), variabilitas lebih lebar.
- **High traffic**, median paling tinggi (**~65 menit**), dengan sebaran yang lebih besar.



Key Exploratory Findings

Distance vs target


- Scatterplot menunjukkan **hubungan positif yang jelas**, semakin jauh jaraknya, semakin lama waktu pengiriman.
- Variabilitas makin besar saat jarak tinggi (contoh di 15–20 km, ada yang tetap cepat tapi ada juga yang sangat lama).



Key Exploratory Findings

Preparation Time vs target


- Scatterplot menunjukkan **hubungan positif**, meskipun tidak sekuat Distance_km.
- Semakin lama preparation, semakin lama delivery.
- Sebaran data cukup lebar di setiap titik preparation, artinya faktor lain juga berperan (misalnya traffic, weather).



Key Exploratory Findings

Correlation Heatmap

- **Distance_km - Delivery_Time_min = 0.78** korelasi kuat semakin jauh jarak, semakin lama waktu kirim.
- **Preparation_Time_min - Delivery_Time_min = 0.31** korelasi sedang makin lama persiapan, makin lama delivery.
- **Courier_Experience_yrs - Delivery_Time_min = -0.09** korelasi negatif sangat lemah pengalaman kurir hampir tidak memengaruhi.
- Antar fitur numerik (multicollinearity check):
 - Semua nilai antar fitur < 0.1 tidak ada multicollinearity.



Machine Learning Outline

1

Data Splitting



Dataset dibagi menjadi training dan test:

- `X = df.drop(columns=['Order_ID', 'Delivery_Time_min'])`
- `y = df['Delivery_Time_min']`

2

Encoding & Scaling



`OneHotEncoder` untuk kategorikal data, dan numerik diseragamkan dengan **scaling**. Semua langkah ini dirangkum dalam **pipeline** menggunakan **ColumnTransformer**

2

Models



Linear Regression, Random Forest, dan XGBoost

Machine Learning Outline

4

*Hyperparameter
Tuning*

5

*Evaluation
Model*

Baseline Model

Model	MAE	RMSE	R ²	MAPE
Linear Regression	5.90	8.83	0.83	10.41%
Random Forest	7.02	10.21	0.77	13.05%
XGBoost	7.02	10.08	0.77	12.92%

Linear Regression memberikan hasil terbaik, dengan MAE paling rendah yaitu sekitar 5.9 menit dan R² tertinggi 0.83. Sementara Random Forest dan XGBoost performanya mirip, tapi masih lebih rendah dibanding Linear Regression.”

Hyperparameter Tuning

Model	MAE	RMSE	R^2	MAPE
Ridge	5.90	8.82	0.82	10.41%
Lasso	5.90	8.82	0.82	10.41%
ElasticNet	5.90	8.83	0.83	10.42%
Random Forest	6.99	10.13	0.77	13.27%
XGBoost	6.50	9.47	0.80	12.16%

Setelah dilakukan tuning, hasilnya tidak jauh berbeda. Ridge, Lasso, dan ElasticNet menghasilkan performa yang hampir sama dengan MAE sekitar 5.9 menit dan R^2 di kisaran 0.82–0.83. Sementara Random Forest dan XGBoost memang sedikit membaik, tapi tetap belum bisa mengalahkan performa model linear. Ini menguatkan bahwa Linear Regression tetap menjadi model paling optimal.

Conclusion

Model	MAE	RMSE	R^2	MAPE
Linear Regression	5.90	8.83	0.83	10.41%

Model Terbaik: Linear Regression

- MAE = 5.90 menit → rata-rata prediksi meleset sekitar 6 menit.
- RMSE = 8.83 menit → terdapat beberapa error besar (karena $RMSE > MAE$).
- $R^2 = 0.83$ → model mampu menjelaskan 83% variasi pada delivery time.
- MAPE = 10.41% → rata-rata error sekitar 10% dari waktu aktual.

Feature Coefficients

1. Faktor paling berpengaruh positif:


- **Distance_km** (+17.17) faktor utama yang meningkatkan waktu pengantaran.
- **Weather_Snowy** (+9.25) dan **Preparation_Time_min** (+7.00) cuaca salju dan waktu persiapan dapur jelas memperlambat delivery.
- **Weather_Foggy** (+6.00) dan **Weather_Rainy** (+4.64) cuaca buruk menambah delay.

2. Faktor paling berpengaruh negatif:

- **Traffic_Level_Low** (-11.13) kondisi jalan lancar sangat mengurangi waktu pengiriman, sesuai ekspektasi.
- **Traffic_Level_Medium** (-5.45) juga sedikit mempercepat relatif terhadap kondisi lain, meski efeknya lebih kecil.
- **Courier_Experience_yrs** (-1.96) kurir berpengalaman cenderung lebih cepat, walau pengaruhnya kecil.

3. Faktor dengan pengaruh relatif kecil:


- **Time_of_Day** (Morning, Evening, Night) dan **Vehicle_Type** (Car, Scooter) efeknya ada, tapi jauh lebih kecil dibanding faktor utama (jarak, cuaca, dan traffic).



Diagnostik

Actual vs Predict

- Titik-titik tersebar cukup dekat dengan garis ideal
- Pada range delivery time rendah (20–50 menit), prediksi cenderung presisi (titik lebih rapat ke garis).
- Pada delivery time tinggi (>80 menit), mulai muncul penyebaran yang lebih lebar. Model kesulitan menangkap kondisi ekstrem (outlier atau perjalanan jauh).



Recommendation

Optimasi Rute Pengiriman

- Karena *distance* sangat berpengaruh pada waktu antar, perusahaan bisa menggunakan sistem optimasi rute (misalnya integrasi dengan Google Maps API) untuk mengurangi keterlambatan.

Manajemen Waktu pada Cuaca & Traffic

- Saat cuaca buruk atau lalu lintas padat, estimasi waktu bisa ditambah secara otomatis agar lebih realistis. Hal ini mengurangi gap antara estimasi dan waktu aktual.

Transparansi ke Pelanggan

- Berikan estimasi pengiriman yang lebih akurat ($\pm 10\%$ dari aktual sesuai hasil model). Ini meningkatkan kepuasan pelanggan karena ekspektasi lebih realistis.

Thank You!



www.linkedin.com/in/mochamadfiqi



github.com/mfiqi